AI Master Project 3 기

최종 발표

과제명 인증서 관리 AI Agent

멘 티 양필규 , 07003

멘 토 이하나 , 최인지

프로젝트 개요

1. 문제 정의 (Vision / Problem)

어떤 문제를 해결하고자 했는가 ?
서버 ·PC 곳곳에 흩어진 SSL/TLS 인증서를 엑셀 대장으로 수작업 관리해 , 만료를 놓치면 그대로 서비스 장애로 이어지는 문제를 해결합니다 .

왜 이 문제가 중요한가 ? (비즈니스 임팩트)
공인 인증서 최대 유효기간이 398 일 → 200 일 (2026.3) → 47 일 (2029.3) 로 줄어 갱신 횟수가 최대 8 배 늘어납니다 . 수작업은 건당 약 1 시간 (연 130 시간) 이 들고 누락 위험이 커집니다 .

2. 핵심 기능 (Core Features)

무엇을 만들었는가 ?
AWS 서버에 흩어진 인증서를 서버 Agent 가 찾아 등록하고 , 만료 전에 알리고 , 승인된 갱신본을 서버에 직접 설치 · 검증 (실패 시 자동 원복) 하며 , 오케스트레이터가 전체 Agent 를 지휘하는 멀티 에이전트 플랫폼

에이전트 구성 :
오케스트레이터 (Supervisor) → 수집 · 대조검증 · 알림 · 배포 (서버 설치 · 자동 원복) · QA(답변 검증 · 자가 수정) · 유지보수 (자가 진단 · 테스트 게이트 코드 반영)

핵심 기술 스택 :
Claude · Multi-Agent Supervisor · LLM-as-a-Judge · Self-Refine · BM25 한글 2-gram RAG · MCP · AWS(EC2·SES·SSM·CloudFormation) · PostgreSQL · AES-256-GCM

핵심 성과 (Key Achievements)

0.99 초
인증서 100 개 수집 · 파싱 · 저장 (목표 60 초)

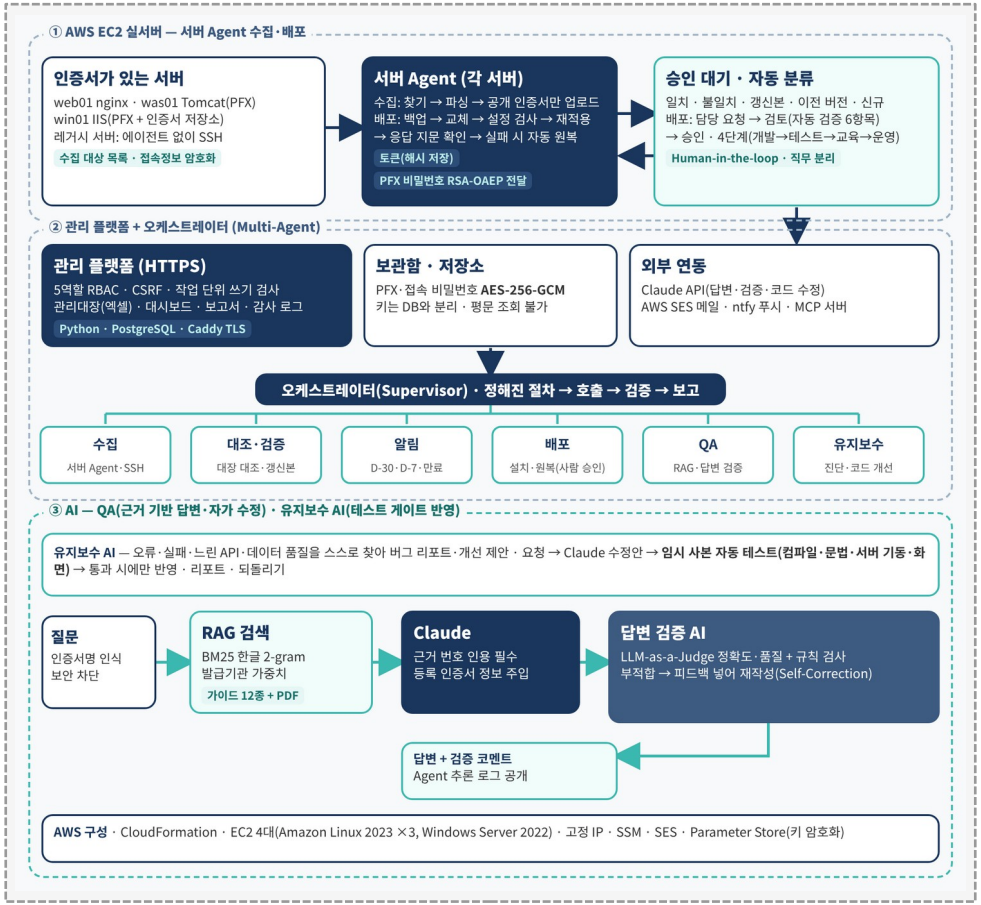
100%
만료 판정 5/5 · 알림 커버리지 36/36 (오탐 0)

~95%
인증서 1 건 사람 작업 시간 : 60 분 → 약 2.7 분 (AWS 실서버 조작 기록)

Key Message

“ 흩어진 인증서는 Agent 가 찾아 분류하고 , 사람은 승인만 합니다 . 틀린 갱신 안내는 검증 AI 가 잡아내 스스로 고칩니다 — 오류 주입 답변 8 건 모두 자가 수정 .”

기술 아키텍처



기술 아키텍처 고려 사항

Agent 는 Supervisor 가 지휘 · 결정은 사람이 · 생성과 검증은 분리

01 Multi-Agent 오케스트레이터 + 유지보수 AI

선택 이유 :
Agent 가 6 개로 늘며 순서 · 검증 · 사람 승인 지점을 한 곳에서 통제할 감독자 (Supervisor) 가 필요

핵심 활용 :
정해진 점검 절차 → Agent 호출 → 유지보수 AI 자가 진단 → 검증 · 보고 (위험 단계는 HITL) · 코드 개선은 자동 테스트 통과 시에만 반영

02 RAG: BM25 한글 2-gram + 인증서 정보 주입

선택 이유 :
가이드가 자주 바뀌어 Fine-tuning 부적합 , 문서 수십 종 규모라 설치 없는 BM25 가 정확 · 경량

핵심 성과 :
정답 가이드 상위 포함률 75% → 100%, 1 위 적중 65% → 85%

03 서버 Agent + Human-in-the-loop 보안 설계

선택 이유 :
인증서 · 개인키는 보안 자산 → 개인키는 서버 밖으로 안 보내고 , 반영은 요청 · 검토 · 승인 직무 분리

구현 포인트 :
PFX 비밀번호 RSA-OAEP 전달 · 설치→검사→응답 확인→실패 시 자동 원복

핵심 기술 과제

핵심 기술 난제 (Hurdle)

LLM 의 갱신 안내는 그럴듯하지만 틀릴 수 있습니다 — 틀린 명령 한 줄이 곧 서비스 장애입니다 .
단순 RAG 챗봇은 한국어 질문을 검색에서 놓치고 (정답 가이드 상위 포함률 75%), 근거와 다른 수치 · 명령 옵션을 섞어 답해 28 문항 중 13 문항만 통과했습니다 .

엔지니어링 접근 방법

어떻게 해결했는가 ? (설계 결정)
① 검색 : 한글 2-gram BM25 + 발급기관 가중치 + 질문 속 인증서 정보 주입 ② 생성 : 문장마다 근거 번호 인용 강제 ③ 검증 : 생성과 분리된 검증 AI 가 채점하고 근거 없는 내용을 지적 → 부적합이면 피드백을 넣어 재작성 (최대 2 회)· 재검증

핵심 알고리즘 / 아키텍처 결정
Self-Refine(Madaan et al., 2023) 피드백 루프 + LLM-as-a-Judge(Zheng et al., 2023) + 규칙 검사 (인용 번호 · 수치 · 명령 옵션) 이중 안전장치 , RAG(Lewis et al., 2020)

왜 이 접근이 필요했는가 ?
LLM 판정도 틀릴 수 있어 규칙 검사로 하한을 고정 (잘못된 인용 시 정확도 59 점 이하) 하고 , 단계별 추론 로그를 남겨 사람이 확인할 수 있게 했습니다 .

Agent 추론 로그 (검증 실험 Q02, 오류 주입)
Plan: 질문 분류 → 인증서 인식 → 근거 검색 → 생성 → 검증 → (부적합 시) 재작성
근거 검색 : G02-2, G11-2, G02-1, G12-2
검증 1 차 : 정확도 15 · 품질 40 → 부적합 (근거 없음 : --force-renewal)
Self-Correction 1 회 : 근거 없는 내용 1 건 반영해 재작성
검증 2 차 : 정확도 98 · 품질 96 → 적합 (--dry-run 복원)

결과 및 성과 (수치로 제시)

8/8
오답 자가 수정 (Self-Correction)
오류 주입 답변 8 건 전부 탐지 → 재작성 후 8 건 적합 , 정확도 28 → 98 점

2.2 배
QA 정답 문항
28 문항 기준 13 → 28 통과 (100%) · AWS 실측 응답 6.1 초

100%
정답 가이드 검색 포함률
75% → 100% (상위 4 개), 1 위 적중 65% → 85%